

Ejercicio 1

Google Play Store es una tienda de aplicaciones móviles para dispositivos con sistema operativo Android. El fichero de datos “**googleplay.csv**” contiene información de 10836 Aplicaciones de Google Play (*App*), clasificadas por categoría (*Category*), calificación general de los usuarios de la aplicación (*Rating*), cantidad de reseñas (*Reviews*), si la app de pago o no (*Type*) y el precio de la app (*Price*).

Variables numéricas	Rating, Reviews, Price
Variables cualitativas	App, Category, Type

Parte 1: Importación de los datos a Rstudio. Limpieza de los datos.

1. Importe los datos teniendo en cuenta lo siguiente:
 - Los datos están separados por “;”
 - Los decimales están separados por “.”
 - Los valores “missings” o valores perdidos están denotados en la base de datos por “NaN”.
2. Una vez importada la base de datos, defina mediante el código (o función de R) apropiado, cuáles son las variables numéricas. De lo contrario no se podrá realizar la práctica.
3. Elimine de la base de datos TODAS las FILAS que tengan un “NaN” en alguna de sus columnas. La nueva base de datos ha de tener una dimensión de 8724 filas y 6 columnas (variables).

Parte 2: Análisis Descriptivo

1. Obtenga una tabla de frecuencias de la variable *Category*. Además, obtenga un diagrama de sectores para representar esta información. Para el diagrama de sectores, buscar alguna forma de mejorar el aspecto del gráfico con funciones R.
2. Usando la tabla de frecuencias anterior, ¿Cuál Categoría tiene el mayor número de apps? ¿Cuales son las 5 categorías con menor número de apps? ¿Cuáles son las 5 categorías con mas disponibilidad de apps?
3. Elija 3 Categorías dentro de la variable *Category*. Obtenga sus histogramas de la calificación general del usuario de la aplicación. En el eje Y del histograma ha de ir la frecuencia absoluta.
4. Con la función de R “**subset**”, construya un nuevo conjunto de datos (un subconjunto de datos) con únicamente los datos de todas las variables pero asociados únicamente a las 3 categorías seleccionadas en el apartado anterior.
5. Con el subconjunto de datos obtenido anteriormente, construya un gráfico conjunto donde estén los 3 diagramas de caja asociados a las categorías (eje X) y la cantidad de reseñas. En caso de ser necesario, aplique algún tipo de transformación al eje Y para cambiar la escala de los datos. ¿Hay datos atípicos? ¿Se observa algún tipo de asimetría?

Ejercicio 2

El hospital de la Paz ha decidido contratar a un grupo de ingenieros informáticos para analizar datos relacionados con un estudio de investigación dirigido por médicos maxilofaciales. En particular, se les pide que analicen los datos “**vitamin.csv**” que contienen información sobre la longitud de 60 dientes incisivos (incluyendo la raíz) de niños (*len*), después de administrarles diferentes dosis de vitamina C (*dose*) y en formatos distintos de esta vitamina (*supp*): mediante zumo de naranja (OJ) ó mediante ácido ascórbico (VC).

Variables numéricas	len (en milímetros), dose (en centilitros)
Variable cualitativa	supp (OJ o VC)

Parte 3: Análisis Bivariante

1. Obtenga un diagrama de medias tal que en el eje X estén las categorías de la variable *supp* y en eje Y las medias de longitud del incisivo. ¿Observa diferencias en la longitud de los incisivos y los dos formatos de vitamina C suministrado a los 60 niños?
2. Calcular el coeficiente de correlación lineal entre:
 - la longitud de los incisivos y la dosis de vitamina C administrada en formato ácido ascórbico.
 - la longitud de los incisivos y la dosis de vitamina C administrada en formato de zumo de naranja.
3. En base a los resultados del apartado anterior, ¿qué formato de vitamina C presenta más correlación lineal entre la longitud de los incisivos y la dosis de vitamina C administrada?
4. Ajuste una recta de regresión lineal a la longitud de los incisivos en función de la dosis administrada de vitamina C. De una interpretación de $\hat{\beta}_1$ en el contexto de estos datos. ¿Es bueno el ajuste?